Royaume du Maroc
Université Hassan 1er
ENCG Settat

Rapport de Projet de Data Science

Analyse de la relation entre le Taux Hypothécaire à 30 ans et le Taux du Trésor à 10 ans

Projet F14 : Taux hypothécaire et taux à 10 ans

Réalisé par :

Btissame Jendi
Abdelkabir Jawahir

Encadré par :

Pr. Abderrahim Larhlimi

Année Universitaire 2026 - 2027

Table des matières

Introduction Générale **2**

1 Chapitre 1 : Présentation et Prétraitement des Données **2**
1.1 Origine et nature des données 2
1.2 Le défi de l'alignement temporel 2
1.3 Vérification visuelle 3

2 Chapitre 2 : Ingénierie des Variables (Feature Engineering) **3**
2.1 Création des variables de retard (Lags) 4
2.2 La notion de "Spread" de crédit 4

3 Chapitre 3 : Modélisation et Méthodologie **4**
3.1 Le Machine Learning appliqué aux séries temporelles 4
3.2 Les modèles implémentés 4
3.3 Métriques d'évaluation 5

4 Chapitre 4 : Résultats, Évaluation et Analyse Critique **5**
4.1 Performances des modèles 5
4.2 Interprétation économétrique 5
4.3 Limites du modèle (Les risques économiques) 6

Conclusion Générale **6**

Introduction Générale

L'économie mondiale est intrinsèquement liée au marché immobilier. Pour la grande majorité des ménages, l'acquisition d'un bien immobilier représente l'investissement financier le plus important de leur vie. Ce projet s'inscrit dans le cadre de l'analyse des séries temporelles financières appliquées au secteur bancaire.

Le taux d'intérêt hypothécaire est le cœur de ce mécanisme : il détermine la capacité d'emprunt des ménages et conditionne la santé du marché immobilier. Cependant, ce taux n'est pas fixé au hasard. Les banques commerciales le construisent en se basant sur un taux dit "sans risque", généralement le taux des obligations d'État à 10 ans.

La problématique centrale de ce projet est la suivante : **Quelle part des variations du taux hypothécaire à 30 ans s'explique par les fluctuations du taux des bons du Trésor à 10 ans ?** Pour répondre à cette question, nous avons divisé notre travail en quatre chapitres. Le premier chapitre sera consacré à la présentation des données et à leur nettoyage. Le deuxième détaillera la phase d'ingénierie des variables (Feature Engineering). Le troisième présentera la méthodologie de modélisation. Enfin, le quatrième chapitre analysera les résultats obtenus et discutera des limites économiques de notre modèle.

1 Chapitre 1 : Présentation et Prétraitement des Données

1.1 Origine et nature des données

Pour mener à bien cette étude, nous avons utilisé des données publiques, fiables et reconnues dans le monde de la finance : la base de données **FRED** (Federal Reserve Economic Data) de la Banque Fédérale de Réserve de Saint-Louis. Deux jeux de données ont été extraits :

— **MORTGAGE30US** : Il s'agit du taux hypothécaire moyen à 30 ans aux États-Unis. Cette série est publiée à une fréquence **hebdomadaire** (chaque jeudi) et couvre la période allant de 1971 à nos jours.

— **DGS10** : Il s'agit du taux de rendement des obligations du Trésor américain à 10 ans. Contrairement au taux hypothécaire, cette série est mesurée à une fréquence **quotidienne** (du lundi au vendredi) depuis 1962.

1.2 Le défi de l'alignement temporel

La première difficulté majeure de ce projet réside dans la différence de fréquence entre les deux séries. Il est impossible de modéliser mathématiquement une relation entre une variable mesurée 52 fois par an (le taux hypothécaire) et une autre mesurée plus de 250 fois par an (le taux à 10 ans).

Pour résoudre ce problème, nous avons procédé en deux étapes :

1. **Agrégation hebdomadaire** : Nous avons utilisé la fonction Python `resample('W').mean()` pour calculer la moyenne du taux à 10 ans sur chaque semaine. Nous avons ainsi réduit le jeu de données de plus de 16 000 lignes à environ 3 300 lignes.
2. **Jointure temporelle** : Pour fusionner les deux DataFrames, une simple jointure sur la date exacte aurait engendré la perte de nombreuses données (les jours fériés bancaires ne correspondant pas toujours). Nous avons donc utilisé la méthode `merge_asof` de la librairie Pandas. Cette fonction permet de faire une jointure sur la date la plus proche, garantissant ainsi un alignement parfait sans perte d'information.

1.3 Vérification visuelle

Après nettoyage et suppression des valeurs manquantes (encodées en `NaN`), notre jeu de données final contient **2898 observations** allant de 1971 à aujourd'hui. La figure 1 illustre l'évolution conjointe des deux taux sur plus de 50 ans.

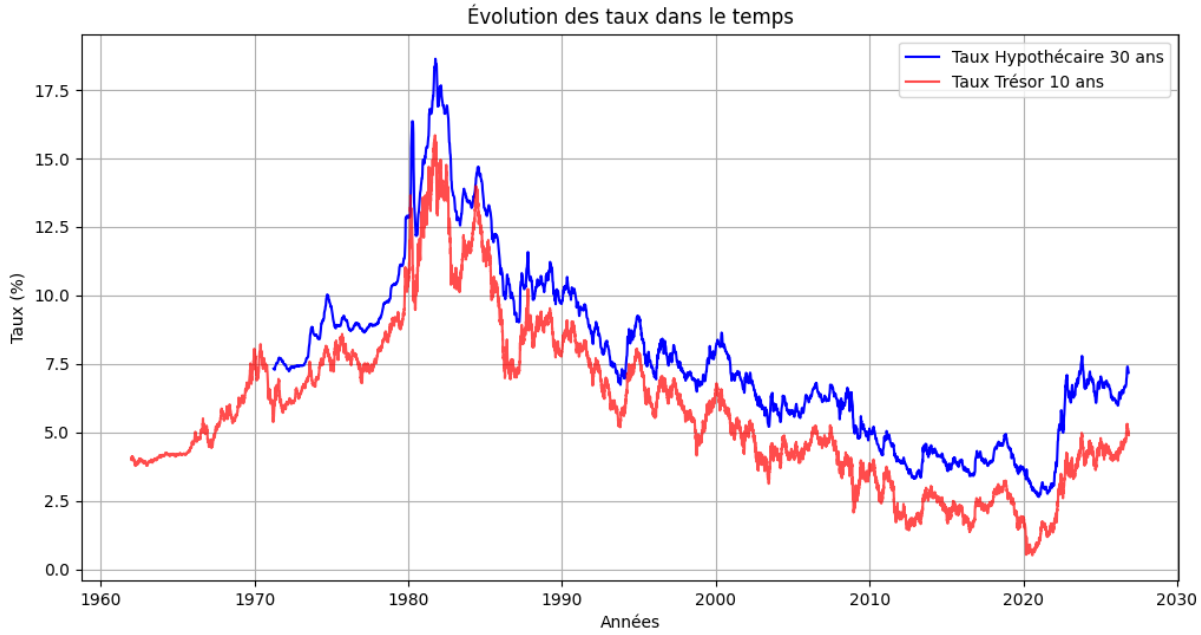


FIGURE 1 – Évolution historique des taux hypothécaires et du Trésor à 10 ans.

On observe visuellement une très forte corrélation entre les deux courbes, notamment lors du pic historique des taux dans les années 1980 (où le taux hypothécaire a dépassé les 18%). La tendance générale à la baisse depuis les années 2000 est également partagée par les deux séries.

2 Chapitre 2 : Ingénierie des Variables (Feature Engineering)

2.1 Création des variables de retard (Lags)

En économie, il est fréquent qu'une variable réagisse avec un certain délai (time-lag) face à un choc extérieur. Une hausse du taux à 10 ans cette semaine mettra-t-elle une semaine ou un mois à se répercuter sur le taux hypothécaire ? Pour tester cette hypothèse, nous avons créé des variables décalées dans le temps :

— **Taux_10ans_S-1** : La valeur du taux à 10 ans de la semaine précédente.
— **Taux_10ans_S-4** : La valeur du taux à 10 ans d'il y a 4 semaines (soit environ un mois).

2.2 La notion de "Spread" de crédit

Le taux hypothécaire n'est pas strictement égal au taux à 10 ans. Si un particulier emprunte pour acheter une maison, la banque prend un risque de défaut. Le taux hypothécaire est donc construit ainsi :

$$\text{Taux Hypothécaire} = \text{Taux à 10 ans} + \text{Spread de crédit} \tag{1}$$

Le **Spread** représente la marge bénéficiaire et la prime de risque de la banque. Nous avons donc créé une variable calculant la différence exacte entre les deux taux pour chaque semaine, ce qui nous permettra d'analyser le comportement des banques.

3 Chapitre 3 : Modélisation et Méthodologie

3.1 Le Machine Learning appliqué aux séries temporelles

Pour modéliser cette relation, nous avons utilisé la régression linéaire, une méthode statistique classique. Cependant, en Data Science financière, il existe une règle d'or : **on ne prédit pas le passé avec le futur**.

C'est pourquoi nous n'avons pas utilisé la validation croisée aléatoire (Random Cross-Validation). Si on mélangeait aléatoirement les données de 1980 et de 2020, le modèle serait biaisé. Nous avons opté pour une séparation chronologique stricte (Train/Test Split) :

— **Données d'entraînement (Train)** : De 1971 à 2010 (2071 semaines). Le modèle apprend sur cette période.
— **Données de test (Test)** : De 2011 à aujourd'hui (827 semaines). Le modèle est évalué sur des données qu'il n'a jamais vues.

3.2 Les modèles implémentés

Deux modèles de régression linéaire (via la librairie *Scikit-Learn*) ont été entraînés :

1. **Le Modèle de Référence (Simple)** : Il tente de prédire le taux à 30 ans en utilisant uniquement le taux à 10 ans de la semaine en cours.

2. **Le Modèle avec Retards** : Il intègre le taux à 10 ans actuel, ainsi que les variables décalées (`S-1` et `S-4`).

3.3 Métriques d'évaluation

Pour juger de la qualité des prédictions, nous avons utilisé deux métriques standards :

— **Le R^2 (Coefficient de détermination)** : Il varie entre 0 et 1. Il indique le pourcentage de variance de la variable cible expliqué par le modèle.

— **Le RMSE (Root Mean Squared Error)** : Il mesure l'erreur moyenne de prédiction en points de pourcentage. Plus il est proche de 0, plus le modèle est précis.

4 Chapitre 4 : Résultats, Évaluation et Analyse Critique

4.1 Performances des modèles

Les résultats obtenus sur la période de test (2011-2024) sont présentés dans le tableau 1.

Modèle	R^2	**RMSE**
Modèle 1 (Simple)	0.7855	0.6171
Modèle 2 (Avec retards)	0.7606	0.6518

TABLE 1 – Comparaison des performances des deux modèles.

4.2 Interprétation économétrique

Le modèle simple est le plus performant. Le taux à 10 ans explique à lui seul **78,55%** de la variance du taux hypothécaire. L'ajout de retards (Modèle 2) dégrade légèrement le modèle, ce qui prouve que le marché hypothécaire est extrêmement réactif : les banques intègrent les variations du marché obligataire de manière quasi-instantanée.

La figure 2 illustre la superposition des prédictions du modèle avec les taux réels. Les courbes suivent une trajectoire très similaire.

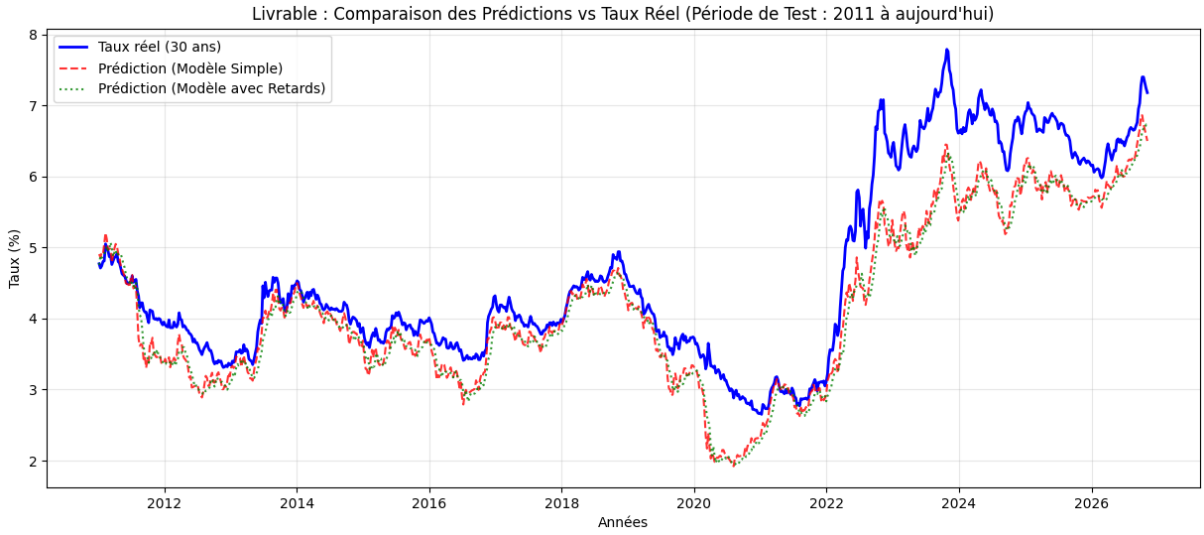


FIGURE 2 – Superposition des prédictions vs Taux réels (2011 - Aujourd'hui).

4.3 Limites du modèle (Les risques économiques)

Comme exigé dans le cahier des charges, plusieurs limites majeures doivent être soulignées :

- **Corrélation n'est pas causalité** : Même avec un R^2 de 78%, le taux à 10 ans ne "cause" pas mathématiquement le taux hypothécaire. Les deux variables sont en réalité influencées par un facteur commun : les décisions de politique monétaire de la Banque Centrale (la Fed).
- **L'impact du Spread lors des crises** : Si on observe attentivement la figure 2, on remarque que lors de la remontée brutale des taux en 2022-2023, notre modèle sous-estime le taux réel. Cet écart s'explique par le Spread : les banques ont augmenté leur marge pour se protéger de l'inflation et du risque de crédit. Le modèle ne capte pas cette variable.
- **Instabilité temporelle** : La relation entre les taux n'est pas stable sur 50 ans. La dynamique des taux zéro (2010-2020) est totalement différente de celle des années 1980.

Conclusion Générale

Ce projet de Data Science nous a permis de quantifier avec précision l'impact du marché obligataire sur le financement immobilier. En appliquant des techniques rigoureuses de nettoyage, d'alignement temporel et de modélisation, nous avons démontré qu'un modèle linéaire simple, basé uniquement sur le taux à 10 ans, parvient à expliquer près de 80% de la dynamique du taux hypothécaire à 30 ans.

Cependant, la Data Science ne se résume pas à obtenir un bon R^2. L'analyse des limites économiques est tout aussi cruciale. Nous avons vu que le taux hypothécaire n'est

pas un simple miroir du taux d'État : la marge des banques (le spread de crédit) joue un rôle fondamental, particulièrement lors des chocs macroéconomiques récents.

Pour de futurs travaux, il serait pertinent d'enrichir ce modèle avec d'autres variables explicatives, telles que le taux de chômage, l'inflation (CPI) ou encore les indicateurs de confiance des ménages, afin de capturer la prime de risque des banques de manière plus précise.